

Modelado predictivo de precios de vino

Máster y asignatura

Máster en Big Data & Business Intelligence 2025/2026 | Asignatura 7: Modelado Predictivo con Machine Learning.

Integrantes

[Completar con los nombres de todas las personas del grupo.]

Vinculación con el TFM

[Completar con el título, objetivo aprobado y justificación de cómo este análisis contribuye al TFM. Verificar con el primer avance antes de entregar.]

Objetivo de este trabajo

Analizar los precios recopilados de vinos en comercios de Costa Rica, estimar el precio equivalente a 750 ml y explorar la clasificación de segmentos de precio y la segmentación no supervisada de productos.

Estado del documento

Memoria generada desde el notebook y los resultados guardados. Los campos entre corchetes requieren información del grupo; no deben quedar pendientes en la entrega final.

1. Introducción y descripción del dataset

Contexto

El proyecto utiliza registros de precios de vinos capturados mediante scraping. La predicción de precio comparable puede apoyar el seguimiento del mercado y la comparación entre formatos. La relación concreta con el TFM debe ser confirmada por el grupo.

Fuente y cobertura

El archivo contiene 4,170 observaciones, 13 variables, tres comercios y fechas entre 2026-09-10 y 2026-09-29. La unidad observacional es un producto registrado en una fecha y comercio.

Variables

Incluye fecha, categoría, precio de lista/oferta, descuento, volumen, precio final, descripción del producto, comercio, precio equivalente por 750 ml, segmento de precio y tipos de cambio.

Objetivo y justificación

Para regresión se usa precio_equivalente_750ml_crc, en colones, para hacer comparables presentaciones distintas. El conjunto es propio y directamente relacionado con precios de vino; debe añadirse la justificación vinculada al objetivo aprobado del TFM.

2. Preparación y análisis exploratorio

Calidad

No se detectaron duplicados exactos. Se apartaron 46 filas con precio equivalente faltante o inferior a 500 CRC y se conservaron 4124 para análisis. El umbral de 500 CRC es provisional: los casos deben revisarse y justificarse, no corregirse automáticamente.

Transformaciones

Se convierten fechas y columnas numéricas a tipos adecuados. Las descripciones se representan con TF-IDF, categoría/comercio con OneHotEncoder, y volumen relativo a 750 ml y fecha con StandardScaler. El preprocesamiento se ajusta dentro de los pipelines.

Datos incompletos y calidad semántica


El CSV contiene etiquetas de segmento y tipos de cambio incompletos; no se imputan porque no son predictores de los modelos reportados. Hay inconsistencias de categorías, títulos y volúmenes de paquetes que pueden afectar resultados.

Lectura exploratoria


Las distribuciones son asimétricas y existen productos de precio alto. Las medianas por categoría y comercio se muestran en el notebook. Las diferencias observadas no deben interpretarse como efectos causales ni como cambios puros de precio, pues la composición del catálogo también varía.

Análisis exploratorio

Distribución del precio equivalente




Precio por categoría



Se excluyen del gráfico 46 registros con precio equivalente inferior a 500 CRC.

Mediana diaria del precio equivalente



3. Modelo supervisado principal: regresión

Ridge combina regularización lineal con variables de texto dispersas. Se reservaron las fechas del 26 al 29 de septiembre de 2026 para la prueba y se seleccionó alpha mediante validación cronológica por bloques de fechas.

modelo	MAE_CRC	RMSE_CRC	R2
Mediana de entrenamiento	2,826.51	3,943.07	-0.053
Ridge alpha=0.1	701.51	1,475.91	0.852

Las métricas corresponden a la partición cronológica reservada y a los datos disponibles.

4. Modelo avanzado y análisis no supervisado

Extensión multiclase

La regresión logística predice `segmento_precio` con descripción, categoría, comercio, volumen y fecha, sin incluir variables de precio como entradas. F1 macro en la prueba: 0.926 sobre 782 observaciones etiquetadas. Las etiquetas de origen tienen faltantes y sus umbrales deben documentarse; el resultado no equivale a una validación de esos umbrales.

Clustering

Se agregaron observaciones por descripción de producto, se combinaron TF-IDF reducido mediante TruncatedSVD con precio, volumen y frecuencia estandarizados, y se evaluó KMeans para k de 2 a 6. El mayor silhouette fue 0.408 para $k=2$.

Interpretación de perfiles

Los dos grupos seleccionados separan principalmente productos de 750 ml con mediana de precio cercana a 7.615 CRC y productos de 1.500 ml con mediana cercana a 2.965 CRC por equivalente de 750 ml. Es una segmentación exploratoria sensible al volumen/precio y a la calidad de los nombres; requiere validación de negocio antes de asignarle significado comercial.

Regresión: lectura

Ridge con $\alpha=0.1$ presenta MAE de 701.51 CRC, RMSE de 1,475.91 CRC y R^2 de 0.852. Se compara con una referencia que predice la mediana del conjunto de entrenamiento.


5. Perfiles de producto

Perfiles de los 319 nombres de producto agrupados por el algoritmo. El valor de silhouette máximo fue 0.408 con $k=2$; un valor mayor indica grupos más compactos/separados en esta representación, no segmentos de negocio automáticamente válidos.


cluster	productos	precio_mediano	volumen_mediano	observaciones_mediana
0	264	7615.0	750.0	14.5
1	55	2965.0	1500.0	18.0

Las métricas corresponden a la partición cronológica reservada y a los datos disponibles.

Observado y estimado



Segmentos de productos



6. Conclusiones, limitaciones y trabajo futuro

Conclusiones

El dataset permite construir un baseline reproducible de precio y explorar tanto los segmentos de precio existentes como grupos no supervisados de productos. La evaluación temporal del notebook es más rigurosa que una partición aleatoria, pero solo cubre un periodo corto.

Limitaciones

El precio equivalente puede estar mal calculado para formatos/paquetes; hay 46 registros atípicamente bajos apartados con un umbral provisional; títulos y categorías son inconsistentes; las etiquetas de segmento tienen faltantes; observaciones del mismo producto aparecen en fechas distintas. El desempeño sobre productos nuevos no se ha medido.

Trabajo futuro

Validar anomalías y equivalencias de volumen con reglas de negocio, normalizar productos/categorías, ampliar el periodo, comparar algoritmos, reforzar validación por fechas y productos, y contrastar los clusters con especialistas o criterios comerciales.

Pendiente antes de entregar

Completar nombres del grupo, contexto y objetivo aprobado del TFM, justificación final del dataset, y revisar que las conclusiones respondan a la pregunta acordada con el profesorado.