

Clasificacion de segmentos de precio de vino

Master y asignatura

Master en Big Data & Business Intelligence 2025/2026 | Asignatura 7: Modelado Predictivo con Machine Learning.

Integrantes

[Completar con los nombres de todas las personas del grupo.]

Vinculacion con el TFM

El TFM analiza la oferta y el comportamiento de precios del vino en los catalogos digitales de Walmart Costa Rica, Masxmenos Costa Rica y PriceSmart Costa Rica. Este trabajo usa el mismo dataset y se centra solo en clasificacion, alineada con el analisis de segmentos del TFM.

Opcion de modelo elegida

Se eligio un modelo de clasificacion supervisada. No se presenta regresion como modelo principal.

Objetivo de este trabajo

Predecir el segmento de precio del producto a partir de atributos del catalogo y complementar el analisis con una segmentacion no supervisada de productos.

1. Introduccion y dataset

Contexto

Costa Rica depende principalmente de vinos importados, por lo que el precio final en supermercados refleja formato, cadena comercial, posicionamiento y dinamicas de catalogo. El TFM estudia este mercado minorista con datos publicados en linea.

Fuente y cobertura

El archivo contiene 4,170 observaciones, 13 variables, tres comercios y fechas entre 2026-09-10 y 2026-09-29. La unidad observacional es un producto registrado en una fecha y comercio.

Variable objetivo

La variable objetivo es segmento_precio. El precio equivalente a 750 ml se mantiene para analisis exploratorio y control de coherencia, pero no se usa como predictor del clasificador para evitar fuga de informacion.

Justificacion

Clasificar segmentos aporta valor al TFM porque ayuda a analizar el posicionamiento comercial de la oferta por supermercado, categoria y periodo observado.

2. Preparacion y analisis exploratorio

Calidad

No se detectaron duplicados exactos. Se apartaron 46 filas con precio equivalente faltante o inferior a 500 CRC y se conservaron 4124 para analisis descriptivo. Para clasificacion se usan las filas validas con segmento informado.

Transformaciones

Se convierten fechas y columnas numericas a tipos adecuados. Las descripciones se representan con TF-IDF, categoria/comercio con OneHotEncoder, y volumen, descuento y fecha con StandardScaler. El preprocesamiento se ajusta dentro del pipeline.

Datos incompletos


La columna segmento_precio tiene faltantes; estos registros no se usan para entrenar/evaluar el clasificador. Los tipos de cambio incompletos no se incorporan al modelo.

Lectura exploratoria


Las distribuciones por segmento permiten revisar si las etiquetas reflejan niveles diferenciados de precio. Las diferencias observadas son descriptivas y dependen de la composicion del catalogo.

Analisis exploratorio

Distribucion del precio equivalente




Precio por segmento



Se excluyen del grafico registros con precio equivalente inferior a 500 CRC.

Mediana diaria del precio equivalente



3. Modelo supervisado principal

Clasificador logístico multiclase para predecir segmento_precio. Se usa particion temporal y validacion cronologica por bloques para seleccionar C.

modelo	accuracy	F1_macro	filas_prueba
base: clase mayoritaria (med	0.505	0.168	782
clasificador logistico multiclase C	0.942	0.952	782

Las metricas corresponden a la particion cronologica reservada y a los datos disponibles.

4. Resultados por segmento

El clasificador elegido obtiene accuracy de 0.942 y F1 macro de 0.952.

segmento	precision	recall	f1-score	support
económico	0.925	0.965	0.944	255
medio	0.968	0.919	0.943	395
premium	0.885	0.962	0.922	104
super premium	1.000	1.000	1.000	28

Las metricas corresponden a la particion cronologica reservada y a los datos disponibles.

5. Extension y no supervisado

Extension multiclase

La extension avanzada elegida es un modelo multiclase: se predicen varios segmentos comerciales, no una decision binaria. F1 macro en prueba: 0.952 sobre 782 observaciones.

Clustering

Se agregaron observaciones por descripcion de producto, se combinaron TF-IDF reducido mediante TruncatedSVD con precio, volumen y frecuencia estandarizados, y se evaluo KMeans para k de 2 a 6. El mayor silhouette fue 0.414 para k=2.

Interpretacion de perfiles



Los grupos separan patrones de producto asociados a volumen, precio mediano y frecuencia de observacion. Es una segmentacion exploratoria que requiere validacion de negocio antes de asignarle significado comercial definitivo.

6. Perfiles de producto

Perfiles de los 307 nombres de producto agrupados por KMeans.

cluster	productos	precio_mediano	volumen_mediano	observaciones_mediana
0	257	7670.0	750.0	12.0
1	50	2940.0	1500.0	14.0

Las metricas corresponden a la particion cronologica reservada y a los datos disponibles.



7. Conclusiones y limitaciones

Conclusiones

Se eligio solo clasificacion. El modelo predice segmento_precio y se alinea con el TFM porque apoya el analisis de posicionamiento comercial de la oferta de vinos.

Limitaciones

El periodo observado es corto; los nombres de producto y categorias tienen variantes; los segmentos tienen faltantes y sus umbrales deben documentarse; el desempeno sobre productos nuevos no se ha medido.

Trabajo futuro

Completar nombres del grupo, revisar umbrales de segmento, normalizar catalogo, ampliar el periodo, comparar clasificadores y validar la utilidad de las predicciones dentro del tablero BI.